

1. (Gram–Schmidt process) 有一向量空間基底 $S_1 = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$, 從建構一組單範正交基底 $S_2 = \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$, 其中

$$\mathbf{e}_i^T \mathbf{e}_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

- 選取 $\mathbf{u}_1 = \mathbf{v}_1$, 將其正規化, 得到第一個單位向量 $\mathbf{e}_1 = \mathbf{u}_1 / \|\mathbf{u}_1\|$
- 選取 \mathbf{v}_2 投影至子空間 $\text{span}\{\mathbf{e}_1\}$, 得到殘差向量 \mathbf{u}_2 , 再正規化得 \mathbf{e}_2 .

$$\mathbf{u}_2 = \mathbf{v}_2 - (\mathbf{v}_2^T \mathbf{e}_1) \mathbf{e}_1 \xrightarrow{\text{正規化}} \mathbf{e}_2 = \mathbf{u}_2 / \|\mathbf{u}_2\|$$

- 選取 \mathbf{v}_3 投影至子空間 $\text{span}\{\mathbf{e}_1, \mathbf{e}_2\}$, 得到殘差向量 \mathbf{u}_3 , 再正規化得 \mathbf{e}_3 .

$$\mathbf{u}_3 = \mathbf{v}_3 - (\mathbf{v}_3^T \mathbf{e}_1) \mathbf{e}_1 - (\mathbf{v}_3^T \mathbf{e}_2) \mathbf{e}_2 \xrightarrow{\text{正規化}} \mathbf{e}_3 = \mathbf{u}_3 / \|\mathbf{u}_3\|$$

- 選取 \mathbf{v}_4 投影至子空間 $\text{span}\{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3\}$, 得到殘差向量 \mathbf{u}_4 , 再正規化得 \mathbf{e}_4 .

$$\mathbf{u}_4 = \mathbf{v}_4 - (\mathbf{v}_4^T \mathbf{e}_1) \mathbf{e}_1 - (\mathbf{v}_4^T \mathbf{e}_2) \mathbf{e}_2 - (\mathbf{v}_4^T \mathbf{e}_3) \mathbf{e}_3 \xrightarrow{\text{正規化}} \mathbf{e}_4 = \mathbf{u}_4 / \|\mathbf{u}_4\|$$

- ...

- 選取 \mathbf{v}_r 投影至子空間 $\text{span}\{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3, \dots, \mathbf{e}_{r-1}\}$, 得到殘差向量 \mathbf{u}_r , 再正規化得 \mathbf{e}_r .

$$\mathbf{u}_r = \mathbf{v}_r - \sum_{i=1}^{r-1} (\mathbf{v}_r^T \mathbf{e}_i) \mathbf{e}_i \xrightarrow{\text{正規化}} \mathbf{e}_r = \mathbf{u}_r / \|\mathbf{u}_r\|$$

表格 1 Gram–Schmidt 算法

	殘差向量	正交向量
$r = 1$	$\mathbf{u}_1 = \mathbf{v}_1$	$\mathbf{e}_1 = \frac{\mathbf{u}_1}{\ \mathbf{u}_1\ }$
$2 \leq r \leq n$	$\mathbf{u}_r = \mathbf{v}_r - \sum_{i=1}^{r-1} (\mathbf{v}_r^T \mathbf{e}_i) \mathbf{e}_i$	$\mathbf{e}_r = \frac{\mathbf{u}_r}{\ \mathbf{u}_r\ }$

更多細節可以參考 [這裡](#) 和 [這裡](#), 閱讀時要注意, 不同參考資料中, 變數名稱定義會有不同.

撰寫一 python 程式([hw1.py](#))實作 Gram–Schmidt process, 函數宣告如下:

```
def gram_schmidt(S1: np.ndarray):
    """
    Parameters
    -----
    S1 : np.ndarray
        A m x n matrix with columns that need to be orthogonalized using Gram-Schmidt process.
        It is assumed that vectors in S = [v1 v2 ... vn] are linear independent.

    Returns
    -----
    S2 : np.ndarray
        S2 = [e1 e2 ... en] is a mxn orthogonal matrix such that span(S1)=span(S2)
    """

```

```
S2 = np.zeros (S1.shape)
# write your code here
return S2
```

2. 影像矩陣 $A_{m \times n}$ 進行奇異值分解(SVD), 特徵值由大到小排列.

$$A_{m \times n} = U_{m \times n} \Sigma_{n \times n} V_{n \times n}^T$$

可以保留前 r 個成份, 得到近似影像

$$\bar{A}_{m \times n} = U_{m \times r} \Sigma_{r \times r} V_{n \times r}^T$$

兩張圖像的差異(失真)部分視為雜訊

$$N_r = A - \bar{A}$$

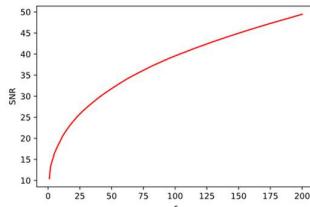
原影像 A 的能量和雜訊的能量比值, 稱為訊號雜訊比(signal-to-noise ratio, SNR), 常以分貝(dB)形式呈現.

$$A_{SNR}[r] = 10 \times \log \frac{\|A\|_F^2}{\|N_r\|_F^2}$$

計算訊號能量請參考 class notebook: 內容庫/補充說明/Energy of a 2D Signal. 參考 [hw2.py](#),

完成下列兩項功能. 當 $1 \leq r \leq 200$,

- ✓ 以 $A_{SNR}[r]$ vs. r 作圖. 參考下圖結果.



- ✓ 寫程式驗證

$$\|N_r\|_F^2 = \sum_{i=r+1}^n \lambda_i \quad \text{or} \quad \|\bar{A}\|_F^2 = \sum_{i=1}^r \lambda_i$$

where λ_i is the eigenvalue of $A^T A$.